

```
In [1]: # Importando o pandas
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
```

```
In [2]: # Carrega os dados para o pandas
dados = pd.read_csv('dados/dados_marketing.csv')
```

```
In [4]: #verificando se o pandas recebeu tudo certo
type(dados)
```


Out[4]: pandas.core.frame.DataFrame

```
In [6]: # #verificando se o pandas recebeu tudo certo
dados.head(5)
```

Out[6]:

	ID	Ano Nascimento	Idade	Escolaridade	Estado Civil	Salario Anual	Filhos em Casa	Adolescentes em Casa	Data Cadastro
0	2795	1958	67	Mestrado	Solteiro	30523	2	1	1/7/2020
1	2285	1954	71	Mestrado	Casado	36634	0	1	12/5/2023
2	115	1966	59	Mestrado	Solteiro	43456	0	1	2/3/2023
3	10470	1979	46	Mestrado	Solteiro	40662	1	0	5/3/2023
4	4065	1976	49	Doutorado	Solteiro	49544	1	0	11/2/2020

5 rows × 29 columns



```
In [7]: # Resumo estatístico para realizar análise exploratória
dados[['Idade', 'Salario Anual', 'pontuacao_gastos']].describe()
```

Out[7]:

	Idade	Salario Anual	pontuacao_gastos
count	1979.000000	1979.000000	1979.000000
mean	56.129864	52271.078828	48.52956
std	11.761482	25487.279575	29.58022
min	29.000000	1730.000000	0.00000
25%	48.000000	35196.000000	24.00000
50%	55.000000	51717.000000	49.00000
75%	66.000000	68277.500000	73.50000
max	84.000000	666666.000000	100.00000

```
In [8]: #deixando todos na mesma escala
padronizador = StandardScaler()
```

```
In [9]: #aplicando a escala as variaveis que serao usadas
dados_padronizados = padronizador.fit_transform(dados[['Idade', 'Salario Anual']])
```

```
In [10]: #verificando se escalou
print(dados_padronizados)

[[ 0.92444842 -0.85350716  1.40231958]
 [ 1.26462756 -0.6136799   0.0497228 ]
 [ 0.24409014 -0.34594931  0.45550183]
 ...
 [ 1.09453799 -0.05388672  0.18498248]
 [-0.77644729  0.845181    1.4361345 ]
 [ 1.09453799 -1.47601413 -0.59276067]]
```

```
In [11]: #definicao do numero de clusters
k = 3
```

```
In [12]: #criando o kmeans
kmeans = KMeans (n_clusters = k)
```

```
In [13]: #treinando o kmeans
kmeans.fit(dados_padronizados)
```

```
Out[13]: KMeans(n_clusters=3)
```


```
In [14]: #dando nome a nova coluna
dados['cluster'] = kmeans.labels_
```

```
In [15]: #verificando
dados.head(5)
```

```
Out[15]:
```

	ID	Ano Nascimento	Idade	Escolaridade	Estado Civil	Salario Anual	Filhos em Casa	Adolescentes em Casa	Data Cadastro
0	2795	1958	67	Mestrado	Solteiro	30523	2	1	1/7/2020
1	2285	1954	71	Mestrado	Casado	36634	0	1	12/5/2023
2	115	1966	59	Mestrado	Solteiro	43456	0	1	2/3/2023
3	10470	1979	46	Mestrado	Solteiro	40662	1	0	5/3/2023
4	4065	1976	49	Doutorado	Solteiro	49544	1	0	11/2/2020

5 rows × 30 columns



```
In [16]: #salvando em uma planilha
dados.to_csv('dados/dados_marketingSegmentado.csv', index = False)
```

```
In [ ]:
```